

PANDAS

▼ Intro

sayı= [10,20,30,40]
 pd.Series(sayı)
 Pandas serisi oluşturur

.ndim : dimension verir.dtype : Data tipini verir

.shape : kaç x kaç olduğunu verir

.sum: toplamı verir

.max(): maksimum değeri verir

▼ DataFrame

• pd.DataFrame(data) : Data yapısını data frame'e çevirir

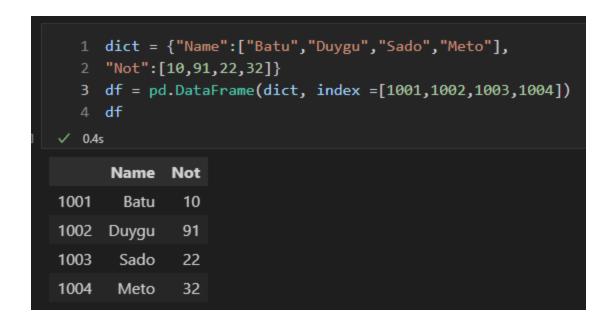
```
s1 = pd.Series([3,2,0,1])
s2 = pd.Series([4,9,2,7])
data = dict(apples = s1, oranges = s2)

df = pd.DataFrame(data)
df
```

df = pd.DataFrame(data, columns=["isim","not"])
 kolon başlıklarını değiştirir
 index = [1,2,3,4] : index numarasını değiştirir

```
data = ([["Batu",10],["Duygu",100],["Sado",22],["Meto",32]])
  2 df = pd.DataFrame(data, columns=["isim", "not"], index = [1,2,3,4]
  3 df
✓ 0.1s
                                                                     Pythor
    isim not
    Batu
           10
2
  Duygu
         100
3
    Sado
           22
4
    Meto
           32
```

• Dictionary üzerinden de data frame oluşturulabilir.



• Böyle de yapılabilir

```
1 dict = {"Name":["Batu","Duygu","Sado","Meto"],
  2 "Not":[10,91,22,32]}
  3 dict_list=[
                 {"isim": "Batu", "Not":10},
                 {"isim": "Duygu", "Not":91},
                 {"isim": "Sado", "Not":22},
  6
                 {"isim":"Meto","Not":32}
  9 df = pd.DataFrame(dict, index =[1001,1002,1003,1004])
 10 df

√ 0.3s

      Name Not
1001
       Batu
              10
1002 Duygu
              91
1003
       Sado
              22
1004
      Meto
              32
```

• .loc["column", "row"] : satır ve sürundaki değeri(leri) verir

```
1 from numpy.random import randn
2 df = pd.DataFrame(randn(3,3), index = ["A","B","C"], columns=[1,2,3])
3 print(df)
4 print(df.loc["A",1])

✓ 0.1s

1 2 3
A 0.029504 -3.375407 0.057888
B 1.312267 1.526281 0.422580
C 1.270968 1.576435 0.655204
0.029503904720519416
```

• .iloc[index num] : o indeksdeki değerleri verir

```
■ 1 print(df.iloc[2])

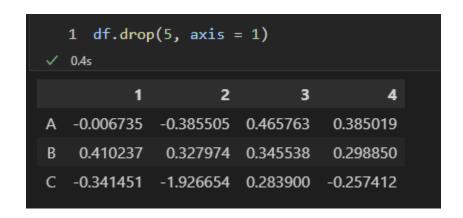
✓ 0.4s

1 -1.977663
2 -2.207510
3 0.684401
Name: C, dtype: float64
```

• yeni kolon eklemek için

```
1 df[4] = pd.Series(randn(3), ["A","B","C"])
  2 df[5] = df[1] + df[3]
     df
✓ 0.1s
          1
                    2
                              3
                                        4
                                                   5
  -0.006735 -0.385505 0.465763
                                  0.385019
                                            0.459027
   0.410237
              0.327974 0.345538
                                  0.298850
                                            0.755775
  -0.341451
             -1.926654 0.283900
                                 -0.257412
                                           -0.057550
```

.drop(değer, axis = 0 veya 1, inplace= True)
 değeri siler, axis = 1 dikey, axis = 0 yatay
 inplace = True : orijinali siler, False : orijinali tutar kopyadan siler



df.columns : kolon başlıkları

```
1 df.columns

v 0.4s

Int64Index([1, 2, 3, 4, 5], dtype='int64')
```

• df[kolon başlığı]head(3) : seçili kolonun ilk 3 elemanı

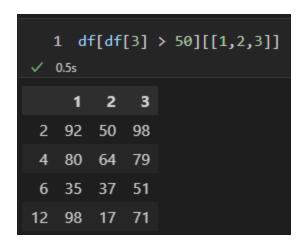
```
1 df[1].head(3)

v 0.7s

0 19
1 38
2 92

Name: 1, dtype: int32
```

• 3. kolondaki 50den büyük olanların olduğu satırı 1 2 3 kolonlarla göster



3. kolon 50den küçük ve 1. kolon 25'ten büyük eşit olanları getirir
 & yerine | eklenirse "or" komunu olur

```
1 df[(df[3] < 50) & (df[1] >= 25)]
✓ 0.1s
    1
        2
            3
                    5
                4
   38
       56
                   61
           19 71
3
   94
       78
           45
               44
                   10
5
   29
       96
           14
               79
                   29
7
   49
       45
           49
               95 89
9
   41
       26
           18
               22
                   98
10
   70
       93
               22 66
           34
13 26
          10 85
                   57
       16
14 50
       65
           16 53 93
```

 Gruplandırma sağlar df.groupby(["key1","key1]).groups : şeklinde yazılabilir

```
1 df.groupby("key").groups
1 df.groupby("key1").get_group("key2")
```

• .reindex(["index1","index2"]) : indekslemeyi değiştirir

```
1 df = df.reindex(["A","B","C","D","E","F","G","H"])
2 print(df)

✓ 0.4₅

1 2 3

A 63.0 65.0 29.0

B NaN NaN NaN

C 83.0 79.0 35.0

D NaN NaN NaN

E 94.0 56.0 51.0

F 46.0 95.0 12.0

G NaN NaN NaN

H 34.0 40.0 52.0
```

.drop("A"): seçili olanı atar
 .drop("A", axis = 1): axis = 0 satır, axis = 1 sütun seçer onu siler

```
1 result = df.drop("A")
2 print(result)

1 2 3

B NaN NaN NaN

C 83.0 79.0 35.0

D NaN NaN NaN

E 94.0 56.0 51.0

F 46.0 95.0 12.0

G NaN NaN NaN

H 34.0 40.0 52.0
```

.isnull() : null NaN değerleri True gösterir
 .notnull() : tam tersi

```
1 result = df.isnull()
2 print(result)

✓ 0.3s

1 2 3

A False False False
B True True True
C False False False
D True True True
E False False False
F False False False
G True True True
H False False False
```

• np.nan : NaN değer ekler

• seçili indekslerdeki null değerler gelir

• .dropna() : NaN değerleri siler

.dropna(how = "any") : NaN varsa satırı siler
 .dropna(how = "all") : sün satırda NaN varsa satırı siler

```
1 result = df.dropna(how = "any")
   2 print(result)

√ 0.2s

      2
          3
F 46.0 95.0 12.0 84.0
H 34.0 40.0 52.0 95.0
   1 result = df.dropna(how = "all")
   2 print(result)
 ✓ 0.3s
      2
          3
A 63.0 65.0 29.0 NaN
B NaN NaN NaN 30.0
C 83.0 79.0 35.0 NaN
D NaN NaN NaN 51.0
E 94.0 56.0 51.0 NaN
F 46.0 95.0 12.0 84.0
H 34.0 40.0 52.0 95.0
```

• subset = [1,2] : sadece o kolondaki değerlere bakar

• .fillna(): NaN değerleri verilen değerle değiştirir

```
1 result = df.fillna( value = "no input")
   2 print(result)
 ✓ 0.3s
     1
           2
                 3
                      4
    63.0
           65.0
                 29.0 no input
B no input no input no input
                             30.0
                 35.0 no input
    83.0
          79.0
C
D no input no input no input
                            51.0
                 51.0 no input
    94.0
Ε
          56.0
    46.0
          95.0
                 12.0
                        84.0
G no input no input no input
    34.0
           40.0
                  52.0
                        95.0
```

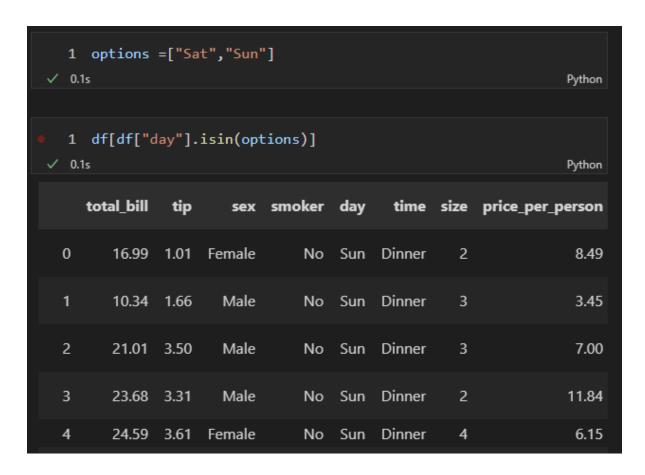
.sum(): 1. kolonları 2. tamamını toplar

• Değerlerin ortalamasını NaN değerlerin içine yazma (ORT : 57.58)

```
def ortalama(df):
           toplam = df.sum().sum()
   3
           adet = df.size - df.isnull().sum().sum()
          return toplam / adet
   6 result = df.fillna(value = ortalama(df))
   7 print(result)
 ✓ 0.1s
      1
            2
                  3
                        4
A 63.000000 65.000000 29.000000 57.578947
B 57.578947 57.578947 57.578947 30.000000
C 83.000000 79.000000 35.000000 57.578947
D 57.578947 57.578947 57.578947 51.000000
E 94.000000 56.000000 51.000000 57.578947
F 46.000000 95.000000 12.000000 84.000000
G 57.578947 57.578947 57.578947 57.578947
H 34.000000 40.000000 52.000000 95.000000
```

.apply(): fonksiyonu data frame uygular

Conditional filtering
 .isin() verilen liste dataFrame'de mi kontrolünü yapar



.set_index("index"): seçilen kolona göre indeksler



• .reset_index() : indeksi resetler

1 ✓ 0	df.reset	_index()							
	Payment ID	total_bill	tip	sex	smoker	day	time	size	pri
0	Sun2959	16.99	1.01	Female	No	Sun	Dinner	2	
1	Sun4608	10.34	1.66	Male	No	Sun	Dinner	3	
2	Sun4458	21.01	3.50	Male	No	Sun	Dinner	3	
3	Sun5260	23.68	3.31	Male	No	Sun	Dinner	2	
4	Sun2251	24.59	3.61	Female	No	Sun	Dinner	4	

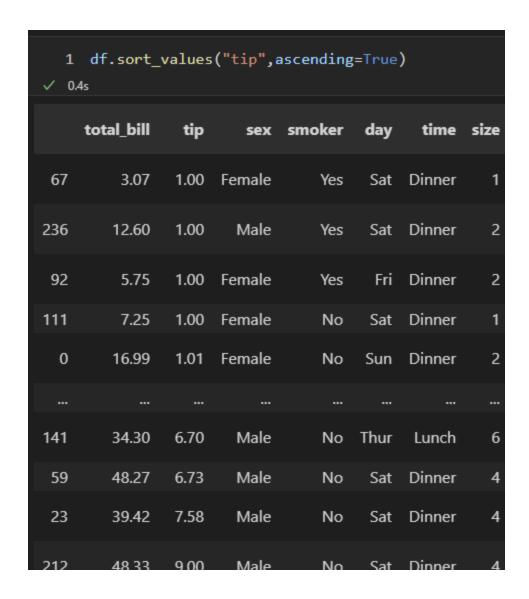
• .apply() : 1den fazla sütunda işlem yaparken

```
def quality(total_bill, tip):
       if tip/total_bill > 0.25:
           return "Generous"
           return "Other"
0.3s
                                                                                    Python
                                                                   df["Quality"] = df[["total_bill","tip"]].apply(lambda df: quality
   (df["total_bill"],df["tip"]),axis = 1)
  df
0.2s
                                                                                    Python
                                                     Payment
    price_per_person Payer Name
                                         CC Number
                                                                     tip_percent
                                                                                 Quality
                                                               yelp
                                                           ID
                           Christy
 2
                8.49
                                   3560325168603410
                                                      Sun2959
                                                                 $$
                                                                            5.94
                                                                                   Other
                      Cunningham
                         Douglas
                3.45
                                   4478071379779230
                                                      Sun4608
                                                                 $$
                                                                           16.05
                                                                                   Other
                           Tucker
                            Travis
 3
                                   6011812112971322
                                                      Sun4458
                                                                 $$
                7.00
                                                                           16.66
                                                                                   Other
                          Walters
                        Nathaniel
               11.84
                                   4676137647685994
 2
                                                      Sun5260
                                                                 $$
                                                                           13.98
                                                                                   Other
```

 np.vectorize(func name): üsttekinin aynısı ama daha kolay yazılıyor ve daha hızlı



 .sort_value("columns", ascending = True) : değere göre artan şekilde sıralar ascending = False : azalan şekilde sıralar



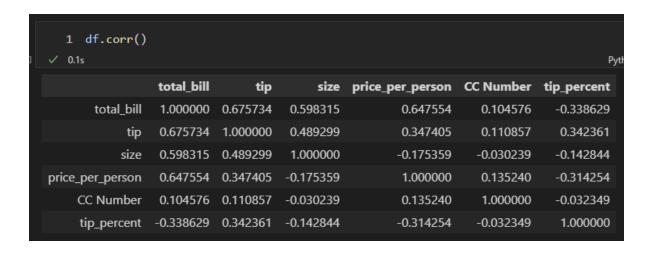
• .idxmax() : maks değerin indeksi, aynısı min için de geçerli

```
1 df["total_bill"].idxmax()

✓ 0.1s

170
```

• .corr(): korelasyon verir



.value_counts() : değerleri sayar

```
1 df["sex"].value_counts()

v 0.4s

Male 157
Female 87
Name: sex, dtype: int64
```

.unique() : eşsiz değerleri gösterir
 .nunique() : eşsiz değerlerin sayısını gösterir

```
1 df["day"].unique()

0.3s

array(['Sun', 'Sat', 'Thur', 'Fri'], dtype=object)
```

• .replace("önceki", "sonraki") : değerleri değiştirir

• .map(): üsttekinin aynısı

• .duplicated(): aynı satır var mı kontrol eder

```
1 df.duplicated()

v 0.1s

0 False
1 False
2 False
3 False
4 False
```

• .drop_duplicates() : tekrar edenleri kaldırır



• .between(a,b, inclusive=True) : a,b değerleri arasındakileri verir.

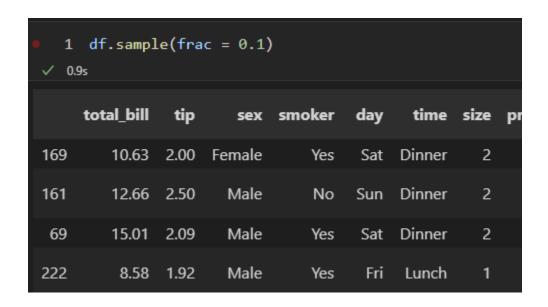
inclusive = True : sınırlar dahil

inclusive = False : sınırlar dahil değil

 .nlargest(sayı, kolon) : seçilen kolonun o sayıda büyükten küçüğe sıralı halini getirir



• .sample(frac = 0.1) : restgele %10unu getirir



▼ Missing Data Operations

• isnull() : null var mı yok mu kontrol eder bool değer verir.

.sum() : kaç null olduğunu gösterir

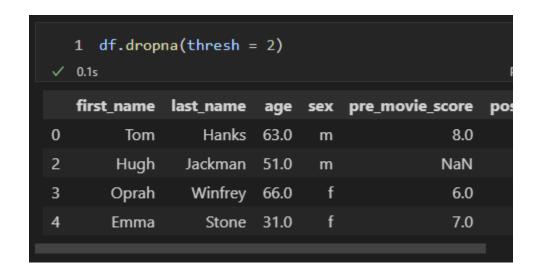
```
1 hotels.isnull().sum()
✓ 0.3s
Output exceeds the size limit. Open the full output
hotel
                                         0
is canceled
                                         0
lead time
                                         0
arrival date year
                                         0
arrival date month
                                         0
arrival date week number
                                         0
arrival date day of month
                                         0
stays_in_weekend_nights
                                         0
stays_in_week_nights
                                         0
adults
                                         0
children
                                         4
babies
                                         0
meal
                                         0
country
                                       488
```

• .drop("column name", axis=1) : kolonu siler

```
1 hotels = hotels.drop("company",axis= 1)
2 hotels

    0.3s
```

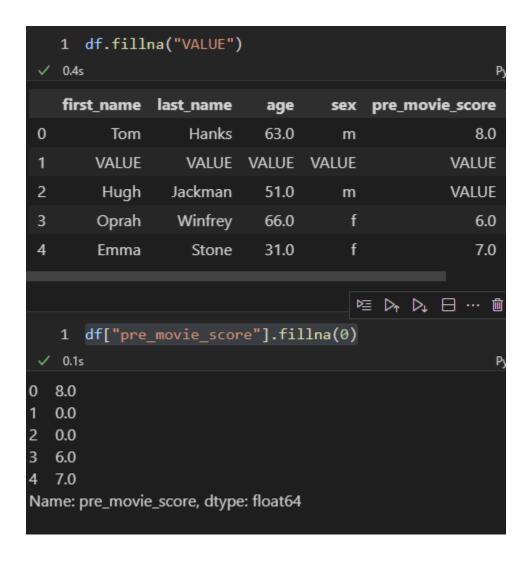
• .dropna(threst = 2) : 2 den fazla NaN varsa siler yoksa tutar



.dropna(subset = ["column name"]) : o kolonda eksik değer varsa atar



• .fillna("value") : kayıp değerleri value olarak doldurur df["pre_movie_score"].fillna(0) : seçilen kolondaki değerleri o olarak doldurur



- seçili kolonları diğer değerlerin ortalaması ile doldurur
- df.fillna(df.mean()) : bütün null değerleri ortalama ile doldurur

```
■ 1 df["pre_movie_score"].fillna(df["pre_movie_score"].mean())

✓ 0.1s

Python

0 8.0
1 7.0
2 7.0
3 6.0
4 7.0

Name: pre_movie_score, dtype: float64
```

• .interpolate() : NaN değerleri üst ve alttaki değerlere göre interpolasyonla doldurur

```
1 airline_tix = {
          "first" : 100,
          "business" : np.nan,
          "economy +" : 50,
          "economy" : 30
   6 }
   7 series = pd.Series(airline_tix)
   8 series
 ✓ 0.4s
first 100.0
business
          NaN
economy +
            50.0
economy
           30.0
dtype: float64
   1 series.interpolate()
 ✓ 0.4s
first
       100.0
business
          75.0
economy +
            50.0
economy
           30.0
dtype: float64
```

▼ Groupby

• .groupby("column name") : seçili kolona göre gruplandırır

```
1 df.groupby("model_year")

v 0.2s

<pandas.core.groupby.generic.DataFrameGroupBy object at 0x000001B6B239D9A0>
```

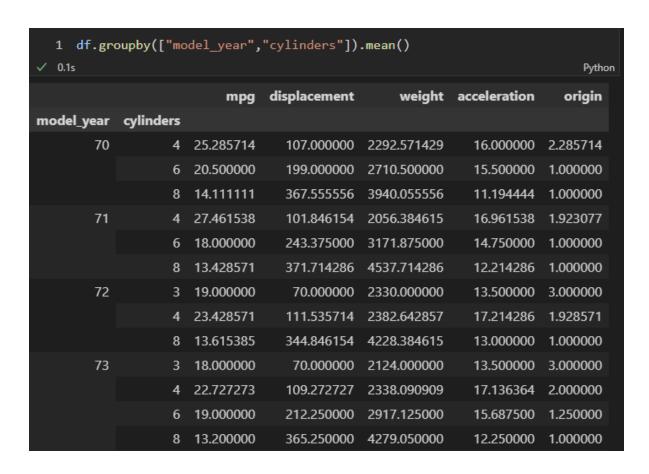
• df.groupby("model_year").mean(): değerlerin ortalamasına göre gruplandırılmış

1 df.gr	oupby("mode	el_year").	mean()			Python
	mpg	cylinders	displacement	weight	acceleration	origin
model_year						
70	17.689655	6.758621	281.413793	3372.793103	12.948276	1.310345
71	21.250000	5.571429	209.750000	2995.428571	15.142857	1.428571
72	18.714286	5.821429	218.375000	3237.714286	15.125000	1.535714
73	17.100000	6.375000	256.875000	3419.025000	14.312500	1.375000
74	22.703704	5.259259	171.740741	2877.925926	16.203704	1.666667

• df.groupby(["model_year","cylinders"]).mean() : model yılı ve silindşir sayısınıa göre gruplandırıp ortalama değerleri verir

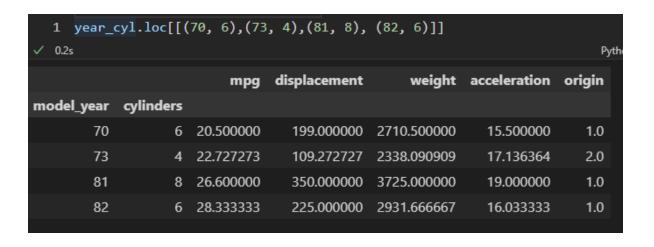
.columns : sonuna eklenirse kolon başlıklarını da verir

["column name"] : sonuna eklenirse sadec o kolondakideğerleri verir

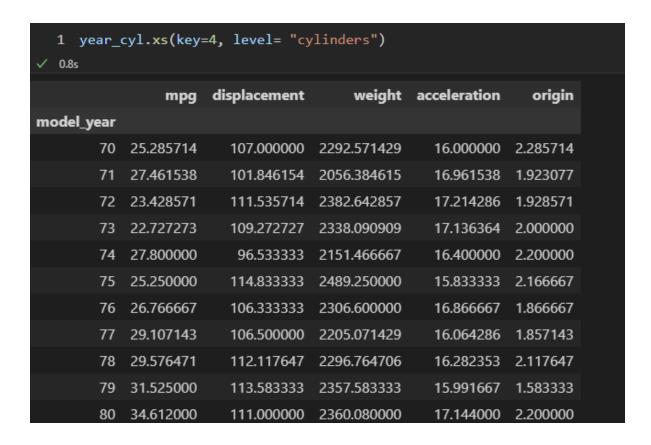


 year_cyl.index.names : index başlıkları year cyl.index.levels : değerler

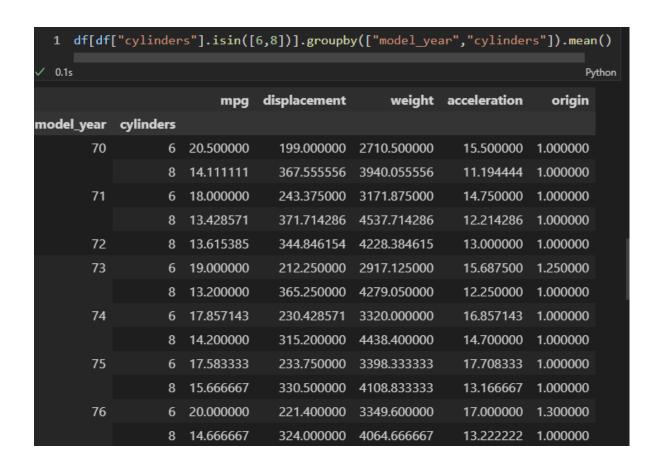
year_cyl.loc[[(70, 6),(73, 4),(81, 8), (82, 6)]] : seçili yuple'daki değerleri verir



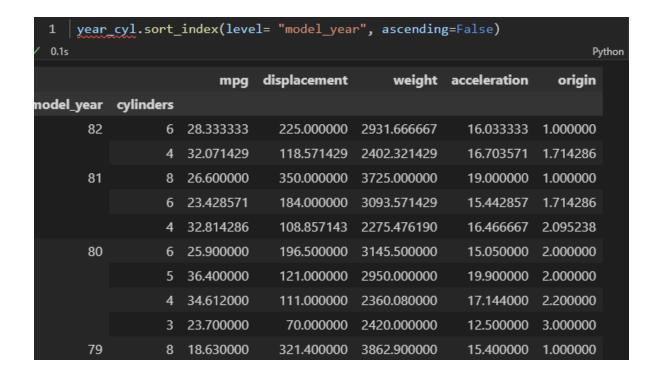
 .xs(key=4, level= "cylinders") : verilen key ve level'e (aranacak alan) göre sonuç çıkarır



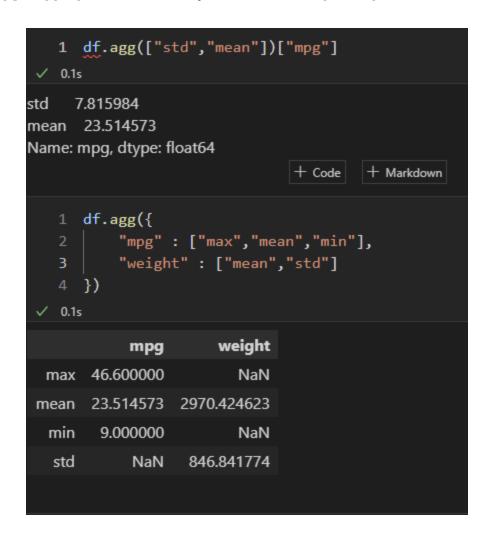
• df[df["cylinders"].isin([6,8])].groupby(["model_year","cylinders"]).mean(): 6,8 silindirlileri model yılı ve silindir sayısına göre gruplar



 year_cyl.sort_index(level= "model_year", ascending=False) : artan şekilde model yılına göre sıralar



• .agg() : aggregation: describe içinden istenen değerleri getirir

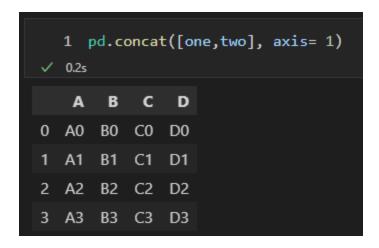


▼ Combining

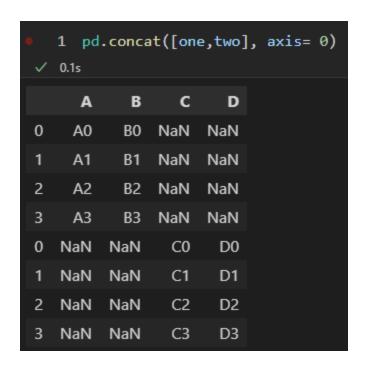
DataFrame'ler

```
1 data_one = {'A': ['A0', 'A1', 'A2', 'A3'],'B': ['B0', 'B1', 'B2', 'B3']}
   2 data_two = {'C': ['C0', 'C1', 'C2', 'C3'], 'D': ['D0', 'D1', 'D2', 'D3']}
   3 one = pd.DataFrame(data_one)
   4 two = pd.DataFrame(data_two)
   5 print(one)
   6 print(two)
                                                                             Python
 А В
0 A0 B0
1 A1 B1
2 A2 B2
3 A3 B3
 C D
0 C0 D0
1 C1 D1
2 C2 D2
3 C3 D3
```

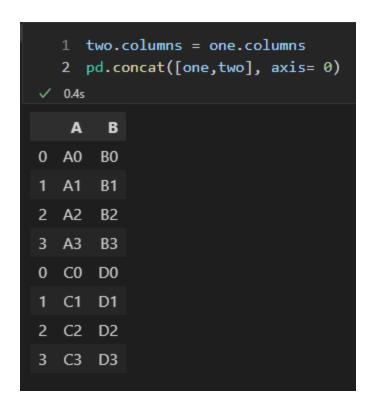
• .concat([one,two], axis= 1) : sütunlara göre birleştirir (Sütunlar yanyana)



• .concat([one,two], axis= 0) : satırlara göre birleştirir (Satırlar yanyana)



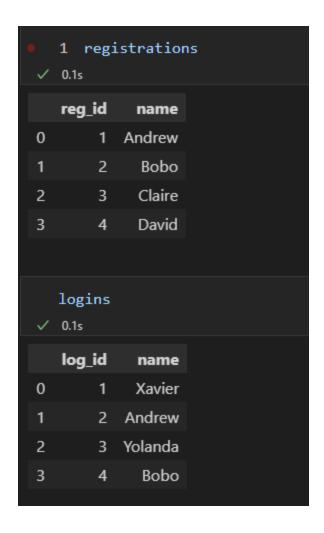
• two.columns = one.columns : kolonları birbirine eşitleyerek alt alta yazdırabiliriz



• mydf.index = range(len(mydf)) : indexi yen,den düzenlemek için

```
1 mydf = pd.concat([one,two], axis= 0)
✓ 0.4s
  1 mydf.index = range(len(mydf))
  2 mydf
✓ 0.3s
   Α
       В
0 A0
      В0
  Α1
      В1
2 A2
     B2
  A3 B3
  C0 D0
5 C1 D1
6 C2 D2
  C3 D3
```

• birleştirilecek dataframe'ler

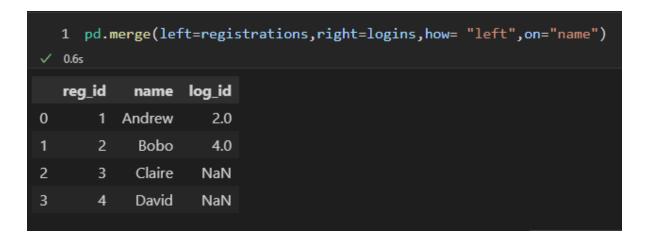


• .merge(registrations,logins,how="inner", on="name") .merge(tablo1,tablo2, how=" ", on= " ") : how metoduna göre tablo 1 ve 2'yi birleştirir

how="inner" : sadece her ikisinde de olanları birleştirir



• pd.merge(left=registrations,right=logins,how= "left",on="name") : soldan birleştirir olmayan değerlere NaN atar



• sağdan birleştirilmiş dataframe

```
1 pd.merge(left=registrations,right=logins,how= "right",on="name")

v 0.1s

reg_id name log_id

0 NaN Xavier 1

1 1.0 Andrew 2

2 NaN Yolanda 3

3 2.0 Bobo 4
```

• other join : bütün değerleri birleştirir olmayanlara NaN atar

```
1 pd.merge(registrations,logins,how= "outer", on= "name")
✓ 0.9s
   reg_id
            name
                   log_id
         Andrew
0
      1.0
                      2.0
1
      2.0
            Bobo
                     4.0
2
      3.0 Claire
                    NaN
3
     4.0
         David
                    NaN
    NaN
           Xavier
                      1.0
4
          Yolanda
5
    NaN
                      3.0
```

kolon başlıklarını değiştirme

```
1 registrations.columns = ["regname","reg_id"]
```

suffixes=("ek1","ek2"): kolon başlıkları aynı olsa da ek1 ve ek2 ile ayrılabilir.
 aksi halde _x ve _y olarak adlandırılır.

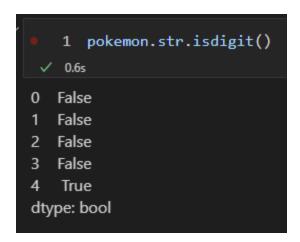
```
1 registrations.columns = ["name","id"]
  2 logins.columns = ["id", "name"]
✓ 0.8s
                               + Code
                                       + Markdown
  1 pd.merge(registrations, logins, how="inner", on="name",
  2 | suffixes=("_reg","_log"))
✓ 0.2s
    name id_reg id_log
0 Andrew
                      2
               1
1
    Bobo
               2
                      4
```

▼ Text Methods

• .split("bölünen") : metni seçilenden parçalarına ayırır

.str.upper() : büyük harf yapar

• .str.isdigit() : sayı olup olmadığına bakar



• tickers.str.split(",").str[0] : 1. sütunu verir

 .str.replace("değişen", "yerine gelen") : stringdeki değerleri değiştirir str.strip() : başta ve sonraki boşlukları siler

.str.capitalize() : ilk harfleri büyük yapar

```
1 messy names.str.capitalize()

v 0.5s

0 Andrew
1 Bobo
2 Claire
dtype: object
```

• fonksiyon olarak da yazılabilir

▼ Input & Output

• df.to_csv("filename.csv", index= True) : df dosyasını csv olarak kaydeder. index= True : yeni index kalır, False : orijinal halindeki indeksle kaydeder

```
1 df.to_csv("filename.csv", index= True)
```

▼ Pivot Table

- Groupby ile neredeyse aynı şekilde kullanılabilir.
- .pivot(data=tablo, index='Company', columns='Product',values='Licenses')

		censes,index='Co t',values='Licen		
Product	Analytics	GPS Positioning	Prediction	Tracking
Company				
Google	150.0	NaN	150.0	300.0
ATT	NaN	NaN	150.0	150.0
Apple	300.0	NaN	NaN	NaN
ВОВО	150.0	NaN	NaN	NaN
CVS Health	NaN	NaN	NaN	450.0
Cisco	300.0	300.0	NaN	NaN
Exxon Mobile	150.0	NaN	NaN	NaN
IKEA	300.0	NaN	NaN	NaN
Microsoft	NaN	NaN	NaN	300.0
Salesforce	750.0	NaN	NaN	NaN
Tesla Inc.	300.0	NaN	150.0	NaN
Walmart	150.0	NaN	NaN	NaN

• Pivot ve Groupby ayni işlemi yapar

```
1 pd.pivot_table(df,index="Company", aggfunc="sum")
    0.1s
```

	A	1:	Cala Daisa
	Account Number	Licenses	Sale Price
Company			
Google	6370194	600	3150000
ATT	1396064	300	1050000
Apple	405886	300	4550000
BOBO	2192650	150	2450000
CVS Health	902797	450	490000
Cisco	4338998	600	4900000
Exxon Mobile	470248	150	2100000
IKEA	420496	300	4550000
Microsoft	1216870	300	350000
Salesforce	2046943	750	7000000
Tesla Inc.	1273370	450	3500000
Walmart	2200450	150	2450000

1 df.groupby("Company").sum()

✓ 0.1s

	Account Number	Licenses	Sale Price
Company			
Google	6370194	600	3150000
ATT	1396064	300	1050000
Apple	405886	300	4550000
BOBO	2192650	150	2450000
CVS Health	902797	450	490000
Cisco	4338998	600	4900000
Exxon Mobile	470248	150	2100000
IKEA	420496	300	4550000